张朱宇

求职意向：AI Agent 开发工程师

电话 18221179721 邮箱 3054038169@qq.com Github github.com/zzy325154

教育背景

吉利学院 计算机科学与技术（本科） 2023.09 – 2027.06

- 相关课程：数据结构与算法、计算机网络、操作系统、数据库原理、Python 程序设计
- 自学方向：大语言模型应用开发、检索增强生成（RAG）、Agent 系统设计

项目经历

> **与「智能体算法工程师」岗位的对应：**岗位要求 Agent 闭环设计、工具调用优化、RAG 与 Agent 融合、Agent 评测体系（成功率/响应延迟/成本）—— 本项目均已实践并给出量化结果：工具调用成功率 71.7%→95.8%、检索命中率 58.3%→100%、首字节响应 231ms、上下文 token 降低 33.4%。

智能体（Agent）系统：工具调用编排 + RAG 检索 *（个人项目）* 2026.xx – 2026.xx

Python / MCP 协议 / Function Calling / ReAct / RAG / DeepSeek API / asyncio / FastAPI / SSE

- **项目描述：**从零实现一个工具调用型智能体，覆盖「感知（检索）— 决策（规划）— 执行（工具调用）— 反思（再决策）」的完整闭环，工具通过 MCP 协议独立成 Server 进程，对外以 HTTP + SSE 提供服务。为深入理解机制，核心循环、上下文管理、错误恢复均**手写实现而非调用框架**，因此具备框架级的问题定位能力。
- **工具接入（MCP）：**按 MCP 协议实现独立 Server 进程，将工具能力以标准协议对外暴露，工具定义与实现只维护一份，本地直调与 MCP 两种接入方式共用——新增工具无需改动 Agent 核心逻辑。基于 stdio 单向传输的特性设计常驻会话适配器，解决跨任务调用导致的 cancel scope 异常。
- **RAG 检索：**自建检索链路——按文档语义结构**分块**（保证条款不被切断、每块带章节标题路径），**向量检索与 BM25 混合召回、RRF 融合排序**——纯向量对「5000 元」这类数字不敏感，纯 BM25 又抓不住口语化提问，二者互补。针对 12 个不含文档原词的口语化提问，命中率由关键词硬匹配的 58.3% 提升至 **100%**；检索延迟 6.7ms（numpy 矩阵运算实现，未引入向量数据库）。本地部署 bge 中文向量模型。
- **调用调度：**设计工具路由与参数校验层，处理模型返回的非法参数与幻觉工具名；对无依赖的工具调用做**并行执行**（asyncio.gather），实测 4 个工具并发下耗时由 805ms 降至 201ms，**降低约 75%**。
- **上下文管理：**实现两级上下文压缩——长工具结果保留首尾、压缩中段；超出预算时从最老轮次开始裁剪，并保证 tool_use 与 tool_result 始终成对出现（否则 API 直接报 400）。10 轮长文档检索对话下输入 token 由 26999 降至 17972（**降低 33.4%**），上下文占用由线性增长转为恒定。**用量估算**：编写 token 估算器并用 API 真实 usage 反推系数校准，误差由 −37% 收敛至 ±1.3%，使预算判断真实可用。
- **稳定性保障：**实现超时控制、指数退避重试与熔断降级三层机制。关键设计是**按故障类型选择性重试**——超时、连接中断等瞬时故障重试，参数非法、业务拒绝等永久错误立即放弃。**在 30% 随机失败 + 5% 超时注入下，工具成功率由 71.7% 提升至 95.8%（+24.1 个百分点）**，失败减少 85%，代价是下游调用量增加 44%；连续失败自动熔断，避免重试放大下游故障。
- **服务化与可观测性：**FastAPI 提供 HTTP 接口与 **SSE 流式输出**，实时推送模型正文与工具调用进度；实测首字节响应 231ms、完整回答 2713ms，**用户等待时间降低约 91%**。会话状态服务端维护并加锁串行化避免历史交错；全链路记录每轮 Thought / Action / Observation，含工具耗时、重试次数与失败原因，支撑成功率统计与问题定位。

专业技能

编程语言 熟练使用 Python（异步编程 asyncio / async-await）；了解 Java / C 基础语法

Agent 开发 手写实现 ReAct 循环、Function Calling 编排与多工具调度；熟悉 MCP 协议接入与自定义 Server；掌握上下文管理与工具错误恢复

RAG 掌握检索链路：语义分块 / 向量检索 / BM25 / RRF 融合；具备本地向量模型（bge）部署与效果评测经验

LLM 应用 熟悉 LLM 的 Messages / Tools / Streaming 接口，具备多厂商适配经验（DeepSeek / Anthropic）

工程能力 FastAPI 接口开发、Pydantic 校验、SSE 流式响应；理解超时/重试/熔断与并发编排的工程实践

自我评价

- 专注 LLM 与 Agent 方向，能独立完成从协议接入、检索链路、工具调度到服务化的完整实现，对工具调用与检索机制有实践层面的理解，习惯**用实测数据验证优化效果**而非凭直觉判断。
- 学习能力强，能快速跟进迭代频繁的 AI 生态；遇到问题习惯查阅官方文档定位根因，而非依赖现成答案。
- 项目开发中注重可复现性——所有性能数据均通过固定随机种子的测量脚本得出，结论可被他人验证。